



École Nationale Supérieure
d'Informatique et d'Analyse des Systèmes
- Rabat

Projet de fin d'année

Analyse des signaux ECG pour la détection et la prédiction des maladies cardiovasculaires en utilisant les techniques de Deep Learning

Élèves :
Aya NASSER
Fatima IBAARAREN

Jury :
Pr : Rachid OULAD LHAJ THAMI (Encadrant)
Pr : Sanaa EL FKIHI (Jury)

Année Universitaire 2025-2026

Remerciements

Avant tout, nous remercions Dieu pour nous avoir accordé la force, la persévérance et les moyens nécessaires à la réalisation de ce projet.

Nous adressons notre profonde gratitude à notre encadrant, **Pr. Rachid Oulad Lhaj Thami**, pour son accompagnement, sa disponibilité, ses conseils précieux et son soutien constant tout au long de ce projet. Ses orientations et son expertise ont largement contribué à la réussite de ce travail.

Nous exprimons également nos sincères remerciements à **Pr. Sanaa El Fkihi**, membre du jury, pour l'intérêt qu'elle a porté à notre travail et pour le temps consacré à son évaluation.

Nous remercions également l'ensemble des enseignants de l'École Nationale Supérieure d'Informatique et d'Analyse des Systèmes (ENSIAS) pour la qualité de leur enseignement, ainsi que pour les connaissances et les compétences qu'ils nous ont transmises au cours de notre formation.

Enfin, nous adressons nos remerciements à toutes les personnes qui, de près ou de loin, ont contribué à la réalisation et à l'aboutissement de ce projet par leurs conseils, leurs encouragements et leur soutien.

À toutes et à tous, nous exprimons notre profonde reconnaissance.

Résumé

Les maladies cardiovasculaires représentent l'une des principales causes de mortalité dans le monde. Leur détection précoce constitue donc un enjeu majeur pour l'amélioration du diagnostic, du suivi médical et de la prévention. L'électrocardiogramme, ou ECG, est un examen médical non invasif permettant d'enregistrer l'activité électrique du coeur. Il fournit des informations essentielles sur le rythme cardiaque, la conduction électrique et la présence d'anomalies morphologiques.

Ce projet vise à développer un système basé sur le Deep Learning permettant d'analyser automatiquement des signaux ECG afin de détecter et prédire différentes catégories de maladies cardiovasculaires. Le dataset PTB-XL a été utilisé comme base expérimentale. Les signaux ECG à 12 dérivations ont été prétraités, normalisés, filtrés puis exploités pour entraîner plusieurs architectures profondes : CNN 1D, BiLSTM, CNN-BiLSTM, ResNet1D et CNN optimisé.

Les modèles ont été évalués à l'aide de plusieurs métriques, notamment l'accuracy, le F1-score macro, le rapport de classification et la matrice de confusion. Les résultats montrent que le modèle CNN obtient une accuracy d'environ 69.48%, tandis que le CNN optimisé obtient le meilleur F1 macro avec environ 57.85%. Une interface Streamlit a également été développée afin de permettre l'importation d'un signal ECG, sa visualisation et l'affichage automatique du diagnostic prédit.

Mots-clés : ECG, maladies cardiovasculaires, PTB-XL, Deep Learning, CNN 1D, BiLSTM, ResNet1D, classification, Streamlit.

Abstract

Cardiovascular diseases are among the leading causes of death worldwide. Early detection is therefore crucial for diagnosis support, patient monitoring and prevention. The electrocardiogram, or ECG, is a non-invasive medical examination used to record the electrical activity of the heart. It provides important information about cardiac rhythm, electrical conduction and morphological abnormalities.

This project aims to develop a Deep Learning-based system for automatic ECG signal analysis in order to detect and predict cardiovascular diseases. The PTB-XL dataset was used as the experimental database. Twelve-lead ECG signals were preprocessed, filtered, normalized and used to train several deep learning architectures, including 1D CNN, BiLSTM, CNN-BiLSTM, ResNet1D and an optimized CNN model.

The models were evaluated using accuracy, macro F1-score, classification report and confusion matrix. The CNN model achieved an accuracy of approximately 69.48%, while the optimized CNN achieved the best macro F1-score of approximately 57.85%. A Streamlit interface was also developed to upload ECG signals, visualize leads and display the predicted diagnosis.

Keywords : ECG, cardiovascular diseases, PTB-XL, Deep Learning, 1D CNN, BiLSTM, ResNet1D, classification, Streamlit.

Table des matières

Remerciements **1**

Résumé **2**

Abstract **3**

Introduction générale **9**

1 Contexte général et cadrage du projet **10**

Introduction 10

1.1 Contexte médical 10

1.2 Motivation du projet 11

1.3 Intérêt de l'intelligence artificielle 11

1.4 Problématique 12

1.5 Contraintes et défis 12

1.6 Objectifs du projet 13

Conclusion 13

2 Fondements théoriques, état de l'art et dataset **14**

Introduction 14

2.1 Principe de l'électrocardiogramme 14

2.1.1 Structure d'un battement ECG 15

2.1.2 Rôle des dérivations 15

2.2 Méthodes classiques et Deep Learning 15

2.2.1 Limites des méthodes classiques 16

2.2.2 Intérêt des CNN 1D pour l'ECG 16
2.2.3 Intérêt des modèles récurrents 17
2.3 Présentation du dataset PTB-XL 17
2.4 Classes diagnostiques retenues 18
2.5 Choix des métriques d'évaluation 20
Conclusion 20

3 Conception et réalisation du système proposé 21
Introduction 21
3.1 Vue globale du pipeline 21
3.2 Extraction et préparation des labels 22
3.3 Prétraitement des signaux ECG 22
3.3.1 Filtrage passe-bande 23
3.3.2 Normalisation 24
3.3.3 Gestion de la longueur des signaux 24
3.4 Découpage des données 25
3.5 Architectures développées 26
3.5.1 CNN 1D 26
3.5.2 BiLSTM 27
3.5.3 CNN-BiLSTM 28
3.5.4 ResNet1D 29
3.5.5 CNN optimisé 30
3.6 Stratégie d'entraînement 31
3.7 Environnement technique 32
Conclusion 32

4 Résultats expérimentaux et interface utilisateur 33
Introduction 33
4.1 Paramètres d'entraînement 33
4.2 Comparaison des modèles 34

4.3 Analyse des résultats 35
4.4 Rapports de classification 35
4.4.1 Interprétation par classe 36
4.4.2 Analyse des erreurs 37
4.5 Courbes d'apprentissage et matrices de confusion 37
4.5.1 Courbe d'apprentissage du modèle CNN 38
4.5.2 Matrice de confusion du modèle CNN 39
4.5.3 Courbe d'apprentissage du modèle CNN optimisé 40
4.5.4 Matrice de confusion du modèle CNN optimisé 41
4.6 Interface utilisateur Streamlit 41
4.7 Modèle choisi pour l'interface 42
4.8 Discussion 43
Conclusion 43

5 Limites et perspectives **44**
Introduction 44
5.1 Limites du projet 44
5.2 Perspectives d'amélioration 45
5.2.1 Amélioration des performances 45
5.2.2 Amélioration de l'explicabilité 46
5.2.3 Amélioration de l'interface 46
Conclusion 46

Conclusion générale **47**

Bibliographie **48**

Annexes **49**
5.3 Exemple de pipeline d'entraînement 49
5.4 Classes utilisées dans l'interface 50
5.5 Prétraitement du signal 50

Table des figures

2.1 Distribution des classes diagnostiques du dataset 19
2.2 Visualisation d'un signal ECG représentatif pour chaque classe diagnostique 19

3.1 Pipeline général du système proposé 21
3.2 Comparaison du signal ECG avant et après filtrage passe-bande 23
3.3 Visualisation des 12 dérivations d'un signal ECG 25
3.4 Architecture du modèle CNN 1D 27
3.5 Architecture du modèle BiLSTM 28
3.6 Architecture du modèle CNN-BiLSTM 29
3.7 Architecture du modèle ResNet1D 30
3.8 Architecture du modèle CNN optimisé 31

4.1 Comparaison graphique des modèles selon l'accuracy et le F1 macro 34
4.2 Courbes d'apprentissage du modèle CNN 38
4.3 Matrice de confusion normalisée du modèle CNN 39
4.4 Courbes d'apprentissage du modèle CNN optimisé 40
4.5 Matrice de confusion normalisée du modèle CNN optimisé 41
4.6 Figure del'interface (1) 42
4.7 Figure del'interface (2) 42

Liste des tableaux

2.1 Fichiers principaux du dataset PTB-XL 17
2.2 Classes diagnostiques utilisées dans le projet 18
2.3 Distribution des classes après extraction des labels 18

3.1 Découpage des données 25

4.1 Paramètres d'entraînement 33
4.2 Rapport de classification du modèle CNN 36
4.3 Rapport de classification du modèle CNN optimisé 36

Introduction générale

Les maladies cardiovasculaires constituent un enjeu majeur de santé publique. Leur diagnostic précoce permet d'améliorer la prise en charge des patients, de réduire les risques de complications et d'orienter rapidement les décisions médicales. Parmi les examens les plus utilisés, l'électrocardiogramme occupe une place centrale, car il permet d'enregistrer l'activité électrique du coeur d'une manière simple, rapide et non invasive.

Cependant, l'interprétation d'un ECG demande une expertise médicale importante. Les anomalies peuvent être discrètes, localisées sur certaines dérivations ou confondues avec d'autres pathologies. Dans ce contexte, les méthodes d'intelligence artificielle, et plus particulièrement le Deep Learning, offrent une approche prometteuse pour assister l'analyse des signaux ECG.

Le présent projet s'inscrit dans cette perspective. Il vise à concevoir un système capable d'analyser automatiquement des signaux ECG à 12 dérivations afin de détecter et prédire plusieurs catégories de maladies cardiovasculaires. Pour cela, le dataset PTB-XL est utilisé comme base expérimentale. Plusieurs architectures de Deep Learning sont développées et comparées, notamment CNN, BiLSTM, CNN-BiLSTM, ResNet1D et CNN optimisé.

Le travail ne se limite pas à l'entraînement des modèles. Il comprend également la préparation des données, le prétraitement des signaux, l'évaluation expérimentale, l'analyse des erreurs, la génération des courbes et matrices de confusion, ainsi que la réalisation d'une interface Streamlit permettant de tester le modèle sur un signal ECG.

Chapitre 1

Contexte général et cadrage du projet

Introduction

Ce chapitre présente le cadre général du projet. Il introduit le contexte médical des maladies cardiovasculaires, l'intérêt de l'intelligence artificielle dans l'analyse ECG, la problématique étudiée, les objectifs fixés ainsi que les contraintes rencontrées. Il permet de situer le travail avant d'aborder les aspects théoriques, techniques et expérimentaux.

1.1 Contexte médical

Les maladies cardiovasculaires regroupent un ensemble de pathologies affectant le coeur et les vaisseaux sanguins. Elles incluent notamment l'infarctus du myocarde, les troubles de conduction, les anomalies du segment ST/T, l'hypertrophie cardiaque et les troubles du rythme. Ces maladies constituent un problème majeur de santé publique en raison de leur fréquence, de leur gravité et de leur impact sur la qualité de vie des patients.

L'électrocardiogramme est l'un des examens les plus utilisés pour l'évaluation de l'activité cardiaque. Il permet d'enregistrer les signaux électriques produits par le coeur à travers plusieurs dérivations. Un ECG standard comporte généralement 12 dérivations, chacune offrant une vue différente de l'activité électrique cardiaque. L'interprétation correcte d'un ECG nécessite cependant une expertise médicale importante.

Dans un contexte hospitalier ou clinique, l'ECG est souvent utilisé comme premier outil d'orientation. Il est rapide, peu coûteux et non invasif. Cependant, son interprétation n'est pas toujours évidente, car certaines pathologies produisent des changements très subtils dans la morphologie du signal. Par exemple, une anomalie du segment ST/T peut

être visible seulement sur certaines dérivations, tandis qu'un trouble de conduction peut modifier la largeur ou la forme du complexe QRS. Cette complexité justifie l'intérêt d'un système automatique capable d'analyser simultanément les douze dérivations.

1.2 Motivation du projet

La motivation principale de ce projet est de rapprocher les techniques modernes d'apprentissage profond d'un problème biomédical réel. Les données ECG sont des séries temporelles multivariées : elles évoluent dans le temps et comportent plusieurs canaux correspondant aux dérivations. Cette structure rend le problème plus complexe qu'une classification d'images ou de données tabulaires classiques.

Le choix du sujet est également motivé par l'importance de l'aide à la décision médicale. L'objectif n'est pas de remplacer le médecin, mais de proposer un outil capable de fournir une première indication, de signaler une anomalie possible et de présenter les probabilités associées aux classes diagnostiques. Dans cette logique, le modèle agit comme un support d'analyse permettant d'attirer l'attention sur certains cas.

1.3 Intérêt de l'intelligence artificielle

Avec l'augmentation du volume de données médicales et les progrès récents de l'intelligence artificielle, il devient possible d'assister les professionnels de santé grâce à des systèmes automatiques capables d'analyser les signaux ECG. Le Deep Learning, en particulier, permet d'apprendre directement à partir des signaux bruts sans nécessiter une extraction manuelle complexe des caractéristiques.

Dans le cas des ECG, les réseaux profonds peuvent apprendre des motifs temporels liés à la forme des ondes, à la régularité du rythme, aux variations d'amplitude et aux anomalies présentes sur certaines dérivations. Cette capacité rend les modèles de Deep Learning particulièrement adaptés aux signaux biomédicaux.

1.4 Problématique

L'analyse manuelle des ECG peut être longue, sensible à l'expérience du praticien et parfois difficile lorsque les anomalies sont subtiles. La problématique principale de ce projet est donc la suivante :

> Comment concevoir un système intelligent capable d'analyser automatiquement des signaux ECG à 12 dérivations afin de détecter et prédire les principales classes de maladies cardiovasculaires ?

Cette problématique implique plusieurs défis : la qualité des signaux, le déséquilibre des classes, la sélection d'une architecture adaptée, l'évaluation médicale des performances et la mise à disposition du modèle dans une interface exploitable.

1.5 Contraintes et défis

La réalisation d'un système de classification ECG impose plusieurs contraintes. La première concerne la qualité du signal. Les ECG peuvent contenir du bruit, des variations de ligne de base, des perturbations musculaires ou des artefacts liés au mouvement. Ces perturbations peuvent influencer l'apprentissage si elles ne sont pas correctement traitées.

La deuxième contrainte concerne le déséquilibre des classes. Dans le dataset utilisé, la classe NORM est beaucoup plus représentée que certaines classes pathologiques comme HYP. Un modèle entraîné directement sur ces données peut donc privilégier la classe majoritaire et obtenir une accuracy correcte tout en restant faible sur les classes minoritaires. C'est pourquoi le F1-score macro est utilisé en complément de l'accuracy.

La troisième contrainte est liée à l'interprétation médicale. Un résultat de Deep Learning doit être présenté avec prudence. Une prédiction avec une confiance élevée ne constitue pas un diagnostic médical définitif. Le système doit être compris comme un outil d'aide à l'analyse.

1.6 Objectifs du projet

Les objectifs principaux de ce projet sont :

— étudier les signaux ECG et leur intérêt dans le diagnostic cardiovasculaire ;

— utiliser le dataset PTB-XL comme base de données expérimentale ;

— extraire les classes diagnostiques principales à partir des annotations SCP ;

— prétraiter les signaux ECG par filtrage, normalisation et mise en forme ;

— développer plusieurs modèles de Deep Learning adaptés aux séries temporelles ;

— comparer les performances des modèles CNN, BiLSTM, CNN-BiLSTM, ResNet1D et CNN optimisé ;

— développer une interface Streamlit permettant de tester le modèle sur un signal ECG ;

— analyser les limites du système et proposer des perspectives d'amélioration.

Conclusion

Ce premier chapitre a permis de poser le cadre général du projet. Nous avons présenté l'importance médicale de l'ECG, la motivation de l'utilisation du Deep Learning, la problématique ainsi que les objectifs principaux. Le chapitre suivant présente les bases théoriques nécessaires et le dataset utilisé pour construire le système.

Chapitre 2

Fondements théoriques, état de l'art et dataset

Introduction

Ce chapitre présente les notions essentielles à la compréhension du projet. Il commence par expliquer la structure d'un signal ECG et le rôle des différentes dérivations. Il présente ensuite les méthodes classiques d'analyse ECG, l'apport du Deep Learning et le dataset PTB-XL utilisé dans notre expérimentation.

2.1 Principe de l'électrocardiogramme

L'électrocardiogramme est un signal biomédical représentant l'activité électrique du coeur au cours du temps. Cette activité est générée par la dépolarisation et la repolarisation des cellules cardiaques. Les électrodes placées sur le corps permettent de mesurer les différences de potentiel électrique et de produire plusieurs dérivations.

Un signal ECG typique contient plusieurs éléments caractéristiques :

— l'onde P, liée à la dépolarisation des oreillettes ;

— le complexe QRS, lié à la dépolarisation des ventricules ;

— le segment ST, important pour la détection de certaines anomalies ischémiques ;

— l'onde T, liée à la repolarisation ventriculaire ;

— les intervalles PR, QT et RR, utilisés pour analyser le rythme et la conduction.

Un ECG standard comprend 12 dérivations : I, II, III, aVR, aVL, aVF, V1, V2, V3, V4, V5 et V6. Chaque dérivation observe le coeur selon un axe différent. L'exploitation simultanée de ces dérivations permet d'obtenir une représentation plus complète de l'activité cardiaque.

2.1.1 Structure d'un battement ECG

Un battement ECG peut être vu comme une succession de phases électriques. L'onde P traduit l'activité des oreillettes. Le complexe QRS représente l'activation des ventricules et constitue généralement la partie la plus marquée du signal. Le segment ST et l'onde T donnent des informations importantes sur la repolarisation ventriculaire. Toute modification de ces éléments peut être associée à une anomalie cardiaque.

Dans une approche manuelle, le spécialiste observe la durée, l'amplitude et la morphologie de ces éléments. Dans une approche par Deep Learning, le modèle apprend automatiquement des motifs discriminants sans que ces caractéristiques soient explicitement définies. Cela constitue un avantage important, mais rend également nécessaire une évaluation rigoureuse.

2.1.2 Rôle des dérivations

Les dérivations frontales et précordiales ne portent pas exactement la même information. Les dérivations I, II, III, aVR, aVL et aVF observent l'activité électrique dans le plan frontal, tandis que V1 à V6 observent le coeur dans le plan horizontal. Certaines pathologies peuvent être plus visibles sur un groupe de dérivations que sur un autre. Pour cette raison, le modèle reçoit les douze dérivations en entrée afin de conserver la richesse de l'information disponible.

2.2 Méthodes classiques et Deep Learning

Les méthodes traditionnelles d'analyse ECG reposent souvent sur plusieurs étapes successives : filtrage du bruit, détection des pics R, segmentation des battements, extraction

de caractéristiques et classification. Les caractéristiques peuvent être temporelles, fréquentielles ou morphologiques. Ces méthodes peuvent être performantes, mais elles dépendent fortement de la qualité des caractéristiques extraites manuellement.

Le Deep Learning permet d'apprendre automatiquement des représentations à partir des données brutes. Dans le cas des ECG, les modèles profonds peuvent détecter des motifs temporels complexes liés aux anomalies cardiaques. Les architectures les plus utilisées sont les CNN 1D, les LSTM, les BiLSTM, les modèles hybrides CNN-LSTM, les ResNet 1D et, plus récemment, les Transformers adaptés aux séries temporelles.

2.2.1 Limites des méthodes classiques

Les méthodes classiques nécessitent généralement une étape d'extraction manuelle de caractéristiques. Cette étape peut inclure la détection des pics R, le calcul de la fréquence cardiaque, la mesure de l'intervalle PR, la durée du complexe QRS, l'intervalle QT ou encore des caractéristiques statistiques comme la moyenne et l'écart-type du signal. Ces caractéristiques sont ensuite données à un classifieur.

L'inconvénient de cette approche est que la performance dépend fortement de la qualité des caractéristiques choisies. Si une information importante n'est pas extraite, le classifieur ne pourra pas l'utiliser. De plus, la détection automatique des ondes peut être difficile lorsque le signal est bruité ou lorsque la morphologie est anormale.

2.2.2 Intérêt des CNN 1D pour l'ECG

Les CNN 1D sont adaptés aux signaux temporels, car ils appliquent des filtres le long de l'axe du temps. Ces filtres peuvent apprendre à reconnaître des formes locales : variations rapides, pics, segments, changements d'amplitude ou motifs répétitifs. Dans un ECG, ces motifs peuvent correspondre à des complexes QRS, à des variations du segment ST ou à des anomalies visibles sur certaines dérivations.

2.2.3 Intérêt des modèles récurrents

Les LSTM et BiLSTM sont conçus pour traiter des séquences. Ils peuvent mémoriser des informations temporelles et modéliser des dépendances entre différentes parties du signal. Dans le cas de l'ECG, ils peuvent théoriquement aider à prendre en compte l'évolution du signal sur toute la fenêtre temporelle. Cependant, ils sont souvent plus coûteux à entraîner et peuvent être plus sensibles au surapprentissage.

2.3 Présentation du dataset PTB-XL

PTB-XL est un dataset public d'électrocardiogrammes largement utilisé dans la recherche en apprentissage automatique appliqué à la cardiologie. Il contient plus de 21 000 ECG annotés, enregistrés sur 12 dérivations. Chaque enregistrement est accompagné de métadonnées cliniques et de codes diagnostiques.

Dans ce projet, les signaux à 100 Hz ont été utilisés. Chaque signal est ramené à une taille fixe de 1000 échantillons par dérivation, ce qui correspond à une représentation homogène et directement exploitable par les modèles de Deep Learning.

Le dataset PTB-XL est particulièrement intéressant pour ce projet, car il contient un nombre important d'enregistrements ECG réels, annotés par des experts. Il fournit aussi une organisation par folds stratifiés, ce qui facilite la séparation entre entraînement, validation et test. Cette séparation permet d'évaluer le modèle sur des données qui n'ont pas été vues pendant l'entraînement.

Fichier	**Rôle**
`ptbxl_database.csv`	Métadonnées des enregistrements ECG
`scp_statements.csv`	Description des codes diagnostiques SCP
`records100`	Signaux ECG échantillonnés à 100 Hz

Table 2.1 – Fichiers principaux du dataset PTB-XL

2.4 Classes diagnostiques retenues

Le projet se concentre sur cinq classes diagnostiques principales issues du dataset PTB-XL. Ces classes sont suffisamment générales pour constituer un problème de classification multi-classes adapté à un projet de Deep Learning.

Classe	**Signification**
NORM	ECG normal
MI	Infarctus du myocarde
STTC	Anomalies ST/T
CD	Troubles de conduction
HYP	Hypertrophie cardiaque

TABLE 2.2 – Classes diagnostiques utilisées dans le projet

La distribution des classes montre un déséquilibre important. La classe NORM est majoritaire, tandis que la classe HYP est nettement moins représentée. Ce déséquilibre influence directement les performances du modèle, notamment le recall et le F1-score des classes minoritaires.

Classe	**Nombre d'exemples**
NORM	9119
STTC	4270
CD	4237
MI	2733
HYP	1071

TABLE 2.3 – Distribution des classes après extraction des labels

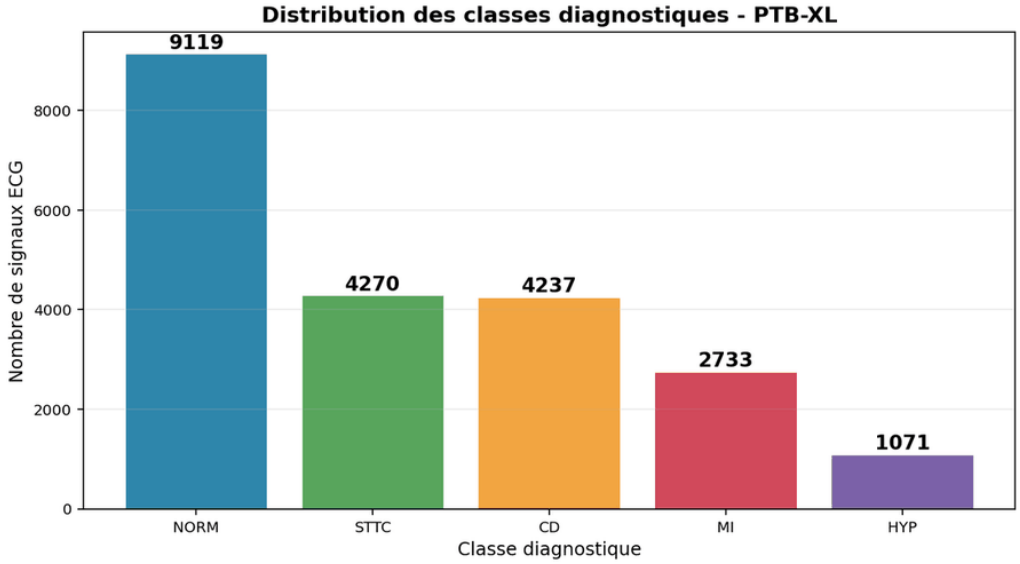


FIGURE 2.1 – Distribution des classes diagnostiques du dataset

La figure suivante illustre un exemple de signal ECG représentatif pour chaque classe étudiée. Cette visualisation permet de mieux comprendre la diversité morphologique des signaux. Même si les différences ne sont pas toujours évidentes à l'oeil nu, certaines classes peuvent présenter des variations d'amplitude, de régularité ou de morphologie qui sont exploitées par les modèles de Deep Learning.

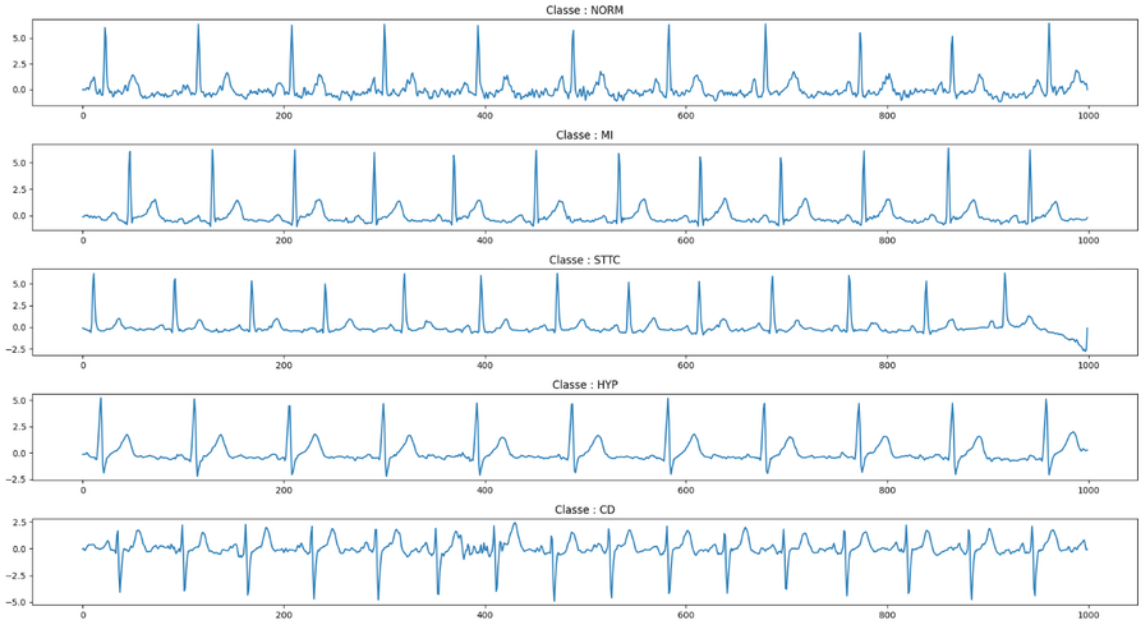


FIGURE 2.2 – Visualisation d'un signal ECG représentatif pour chaque classe diagnostique

2.5 Choix des métriques d'évaluation

Dans un problème de classification médicale, l'accuracy seule n'est pas suffisante. En effet, si une classe est majoritaire, un modèle peut obtenir une bonne accuracy en prédisant souvent cette classe, tout en échouant sur les classes minoritaires. C'est pour cette raison que plusieurs métriques sont utilisées.

— **Accuracy :** proportion totale de prédictions correctes.

— **Précision :** proportion de prédictions positives correctes pour une classe donnée.

— **Recall :** proportion d'exemples d'une classe correctement détectés.

— **F1-score :** moyenne harmonique entre précision et recall.

— **F1 macro :** moyenne des F1-scores de toutes les classes avec le même poids pour chaque classe.

— **Matrice de confusion :** tableau permettant d'observer les confusions entre classes réelles et classes prédites.

Le F1 macro est particulièrement important dans ce projet, car les classes sont déséquilibrées. Il permet de mieux juger la performance du modèle sur l'ensemble des classes, et non uniquement sur la classe majoritaire.

Conclusion

Ce chapitre a présenté les bases médicales et techniques du projet. Nous avons expliqué la structure d'un ECG, le rôle des dérivations, les limites des méthodes classiques et l'intérêt des modèles profonds. Nous avons également détaillé le dataset PTB-XL, les classes diagnostiques utilisées et les métriques d'évaluation retenues. Ces éléments constituent la base de la conception du système présentée dans le chapitre suivant.

Chapitre 3

Conception et réalisation du système proposé

Introduction

Ce chapitre décrit la réalisation technique du système proposé. Il présente le pipeline global, l'extraction des labels, les étapes de prétraitement des signaux ECG, le découpage des données, les architectures de Deep Learning étudiées ainsi que la stratégie d'entraînement utilisée.

3.1 Vue globale du pipeline

Le système développé suit un pipeline complet allant du chargement des données jusqu'à l'affichage du diagnostic dans une interface utilisateur. Cette approche permet de structurer le projet en plusieurs étapes : préparation des données, prétraitement du signal, apprentissage des modèles, évaluation, sauvegarde du modèle et déploiement dans une interface.

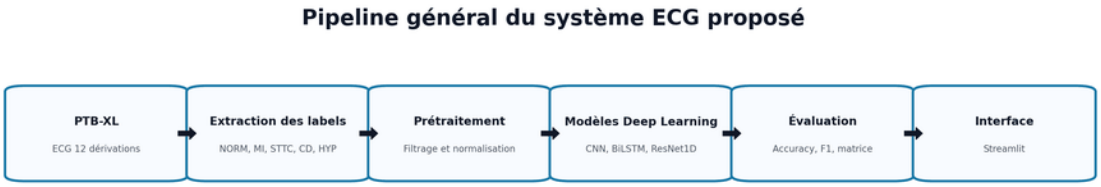


FIGURE 3.1 – Pipeline général du système proposé

Le pipeline commence par la lecture des métadonnées du dataset PTB-XL. Les codes diagnostiques sont ensuite convertis en classes principales. Les signaux ECG sont chargés, filtrés et normalisés. Après cette étape, les données sont divisées en ensembles d'entraînement, de validation et de test. Les modèles sont entraînés sur l'ensemble d'entraînement, ajustés à l'aide de l'ensemble de validation, puis évalués sur l'ensemble de test. Le meilleur modèle est ensuite utilisé dans l'interface Streamlit.

3.2 Extraction et préparation des labels

Les annotations du dataset PTB-XL sont disponibles sous forme de codes SCP. Ces codes ne correspondent pas directement aux classes finales utilisées dans le projet. Il est donc nécessaire de lire le fichier `scp_statements.csv`, d'identifier la classe diagnostique associée à chaque code, puis de sélectionner une classe principale pour chaque ECG.

La fonction d'extraction utilisée parcourt les codes SCP d'un enregistrement, vérifie leur présence dans le fichier de référence, puis récupère la classe diagnostique correspondante. Lorsqu'un ECG contient plusieurs codes, la classe associée au score le plus élevé est retenue. Cette méthode permet de transformer les annotations complexes du dataset en un problème de classification à cinq classes.

Cette étape est essentielle, car une mauvaise extraction des labels peut produire un apprentissage incohérent. Elle constitue donc une partie importante du pipeline expérimental.

3.3 Prétraitement des signaux ECG

Le prétraitement appliqué aux signaux comprend :

— le chargement des fichiers ECG avec la bibliothèque `wfdb` ;

— l'application d'un filtre passe-bande entre 0.5 Hz et 40 Hz ;

— la normalisation de chaque dérivation ;

— le découpage ou le padding pour obtenir une taille fixe de 1000 échantillons ;

— la conversion des signaux au format `float32`.

Le filtrage passe-bande permet de réduire les bruits de basse fréquence et les hautes fréquences parasites. La normalisation rend les dérivations comparables et améliore la stabilité de l'apprentissage.

$$X_{norm} = \frac{X - \mu}{\sigma + 10^{-8}}$$

Dans ce projet, chaque ECG est représenté sous la forme d'une matrice :

$$1000 \times 12$$

où 1000 correspond au nombre d'échantillons temporels et 12 au nombre de dérivations.

3.3.1 Filtrage passe-bande

Le filtrage passe-bande est utilisé pour conserver les fréquences utiles du signal ECG tout en réduisant les perturbations. Les très basses fréquences peuvent correspondre à des variations de ligne de base, tandis que les hautes fréquences peuvent contenir du bruit musculaire ou instrumental. Le choix de la bande 0.5–40 Hz est courant pour conserver les composantes principales du signal ECG dans une application de classification.

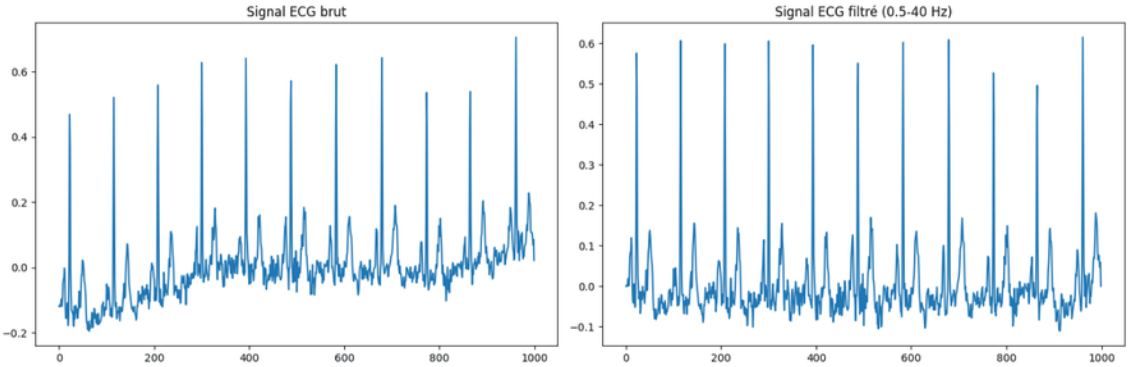


FIGURE 3.2 – Comparaison du signal ECG avant et après filtrage passe-bande

La comparaison avant/après filtrage montre l'intérêt du prétraitement. Le signal brut peut contenir une dérive de la ligne de base ainsi que des perturbations rapides. Après

filtrage, le signal conserve sa structure principale tout en étant plus stable pour l'apprentissage automatique.

3.3.2 Normalisation

La normalisation est appliquée dérivation par dérivation. Elle consiste à centrer le signal autour de zéro et à réduire son échelle par son écart-type. Cette étape améliore la stabilité de l'entraînement, car les réseaux de neurones sont sensibles aux différences d'échelle entre les variables d'entrée.

3.3.3 Gestion de la longueur des signaux

Les modèles de Deep Learning utilisés nécessitent une taille d'entrée fixe. Chaque signal est donc ramené à une longueur de 1000 échantillons. Si un signal est plus long, il est tronqué. S'il est plus court, un padding par zéros est appliqué. Cette stratégie permet de construire un tenseur d'entrée homogène de dimension `(nombre_exemples, 1000, 12)`.

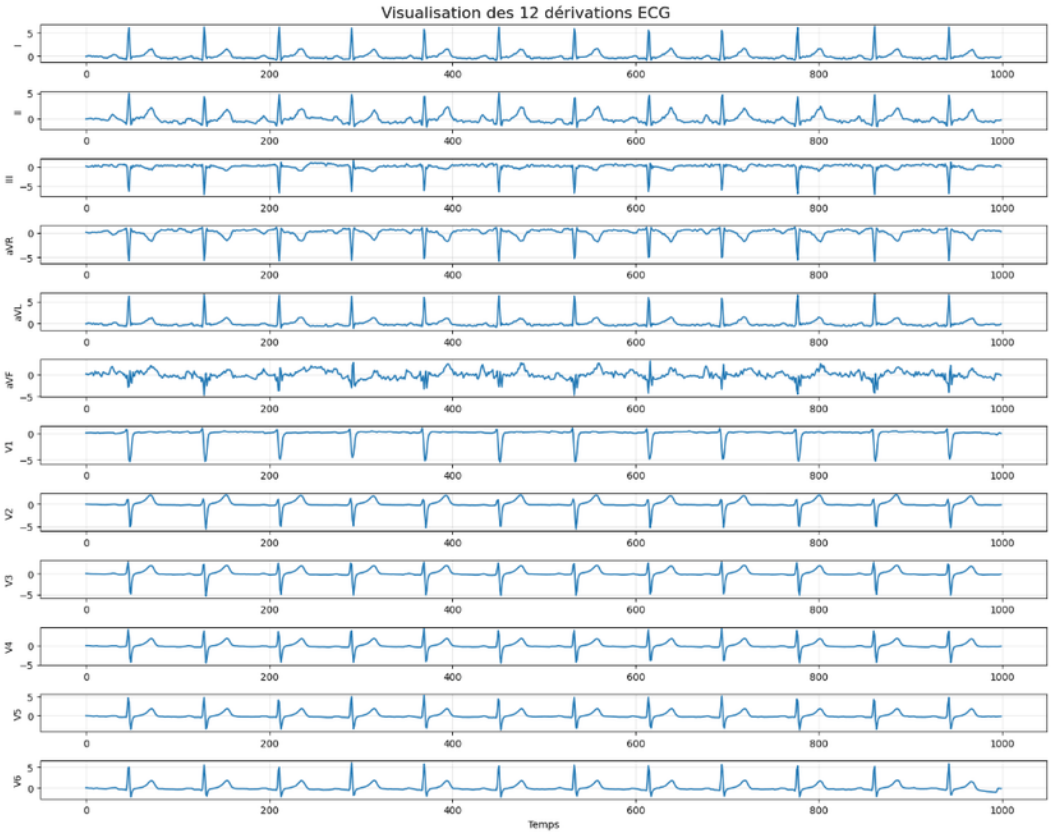


FIGURE 3.3 – Visualisation des 12 dérivations d'un signal ECG

3.4 Découpage des données

Le dataset PTB-XL fournit une colonne `strat_fold` permettant de réaliser un découpage reproductible. Dans ce projet, les folds 1 à 7 sont utilisés pour l'entraînement, le fold 8 pour la validation et les folds 9 et 10 pour le test.

Ensemble	Dimension
Train	14961 signaux
Validation	2150 signaux
Test	4319 signaux

TABLE 3.1 – Découpage des données

L'utilisation d'un ensemble de validation séparé permet de suivre la performance du modèle pendant l'entraînement et de détecter le surapprentissage. L'ensemble de test, quant à lui, n'est utilisé qu'à la fin afin de mesurer la capacité de généralisation du

modèle sur des données non vues.

3.5 Architectures développées

Plusieurs architectures ont été étudiées afin de comparer différentes stratégies d'apprentissage sur les signaux ECG.

3.5.1 CNN 1D

Le CNN 1D est utilisé pour extraire automatiquement des motifs locaux dans le signal ECG. Les couches de convolution parcourent l'axe temporel du signal et apprennent des filtres capables de détecter des formes pertinentes. Le modèle contient des couches `Conv1D`, `BatchNormalization`, `MaxPooling1D`, `GlobalAveragePooling1D` et une couche dense finale avec activation `softmax`.

Le choix du CNN 1D est justifié par la nature temporelle du signal. Contrairement à un CNN 2D utilisé pour les images, le CNN 1D traite directement l'évolution du signal dans le temps. Les couches de pooling réduisent progressivement la dimension temporelle, tandis que les couches de convolution augmentent le niveau d'abstraction des caractéristiques apprises.

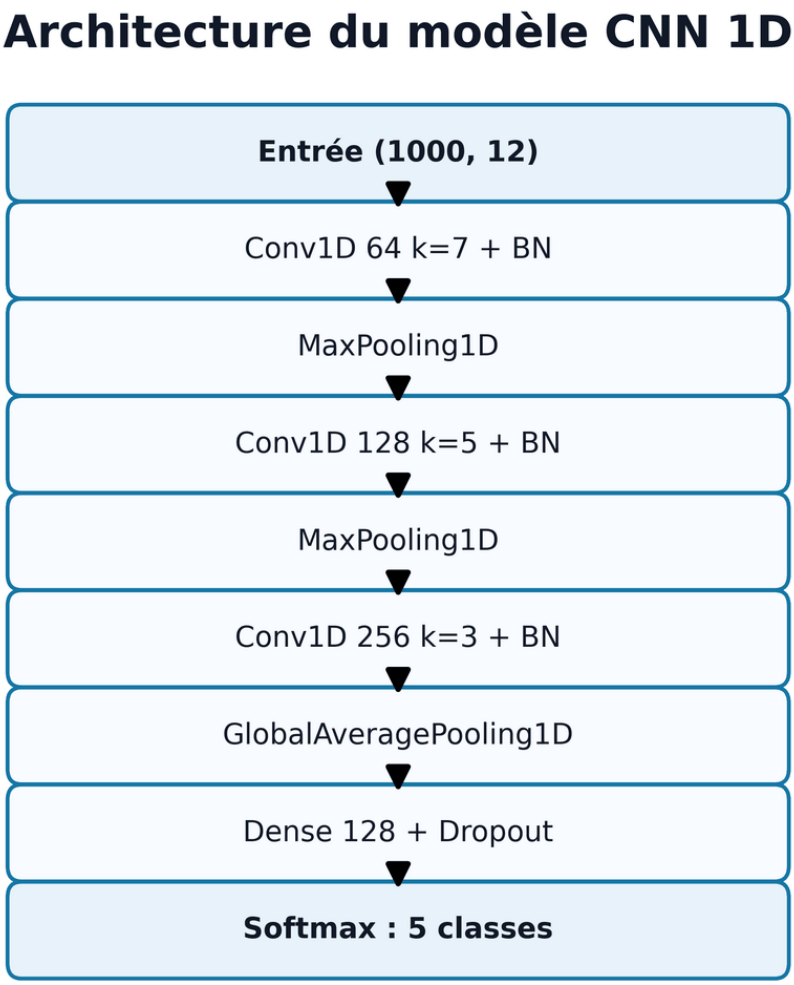


FIGURE 3.4 – Architecture du modèle CNN 1D

3.5.2 BiLSTM

Le modèle BiLSTM est basé sur des couches LSTM bidirectionnelles. Contrairement à un LSTM classique, le BiLSTM lit la séquence dans les deux directions. Cela permet au modèle de prendre en compte le contexte passé et futur du signal ECG.

Ce modèle est intéressant pour les signaux ECG, car certaines anomalies peuvent dépendre de la relation entre plusieurs zones temporelles. Toutefois, les modèles récurrents sont plus lourds que les CNN et nécessitent souvent plus de temps d'entraînement.

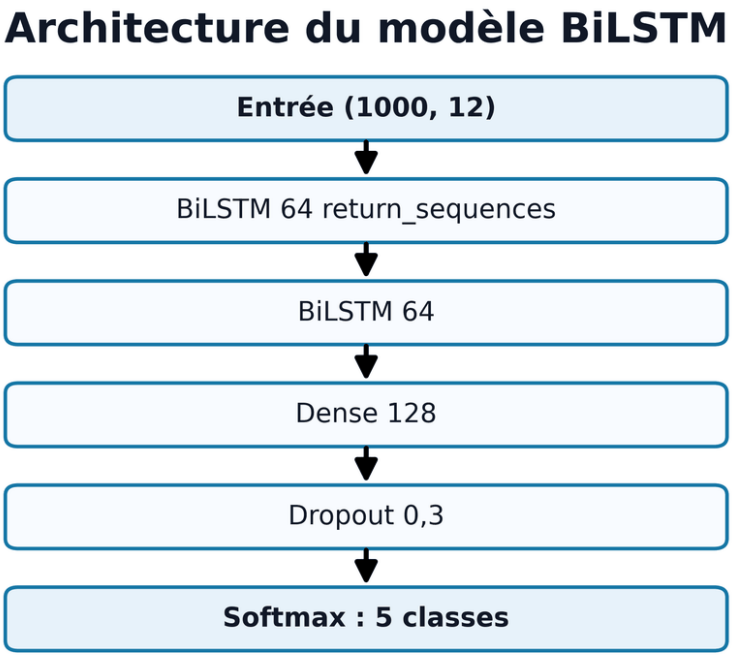


FIGURE 3.5 – Architecture du modèle BiLSTM

3.5.3 CNN-BiLSTM

Le modèle CNN-BiLSTM combine deux approches complémentaires. Les couches CNN extraient d'abord des caractéristiques locales, puis les couches BiLSTM exploitent les dépendances temporelles entre ces caractéristiques.

Cette architecture hybride est souvent utilisée lorsque l'on souhaite bénéficier à la fois de l'extraction locale des convolutions et de la modélisation séquentielle des LSTM. Dans ce projet, elle permet de tester si l'ajout d'une mémoire temporelle après les convolutions améliore la classification.

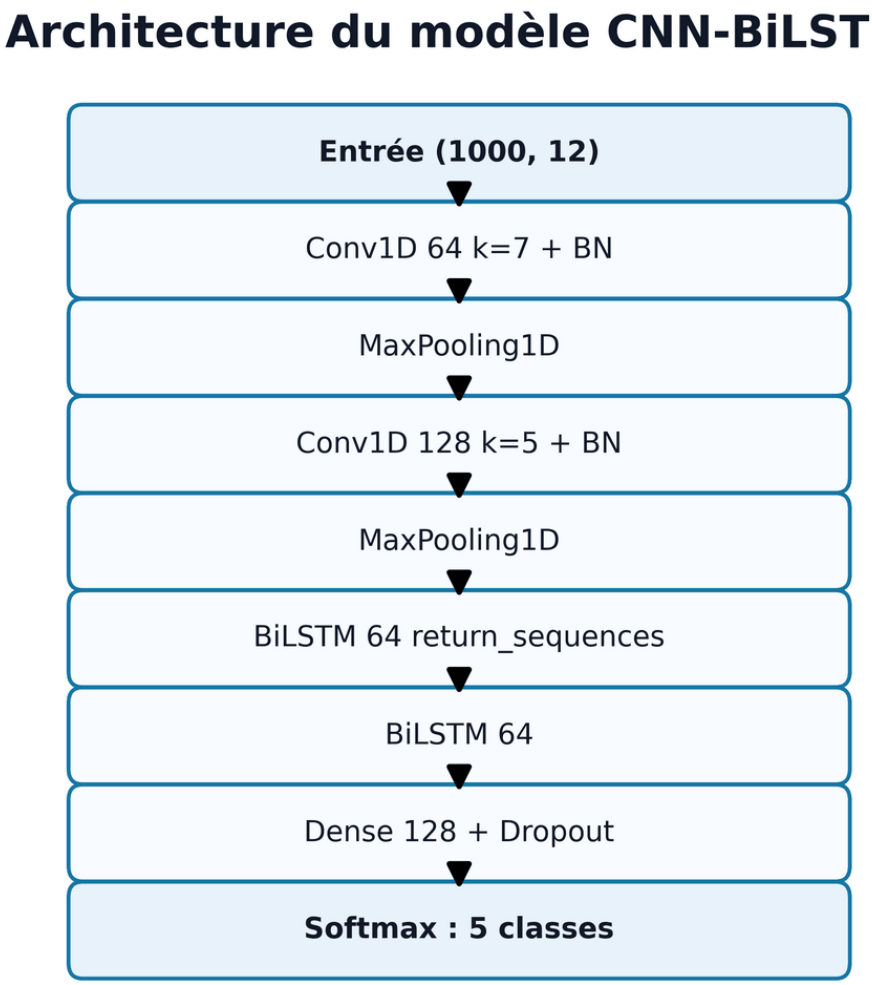


FIGURE 3.6 – Architecture du modèle CNN-BiLSTM

3.5.4 ResNet1D

Le ResNet1D utilise des blocs résiduels. Ces blocs permettent de faciliter l'entraînement de modèles profonds grâce à des connexions directes entre les couches. Cela réduit le risque de disparition du gradient et améliore la stabilité de l'apprentissage.

Les connexions résiduelles permettent au modèle d'apprendre une correction par rapport à l'entrée d'un bloc, plutôt qu'une transformation complète. Ce principe est particulièrement utile lorsque le réseau devient profond.

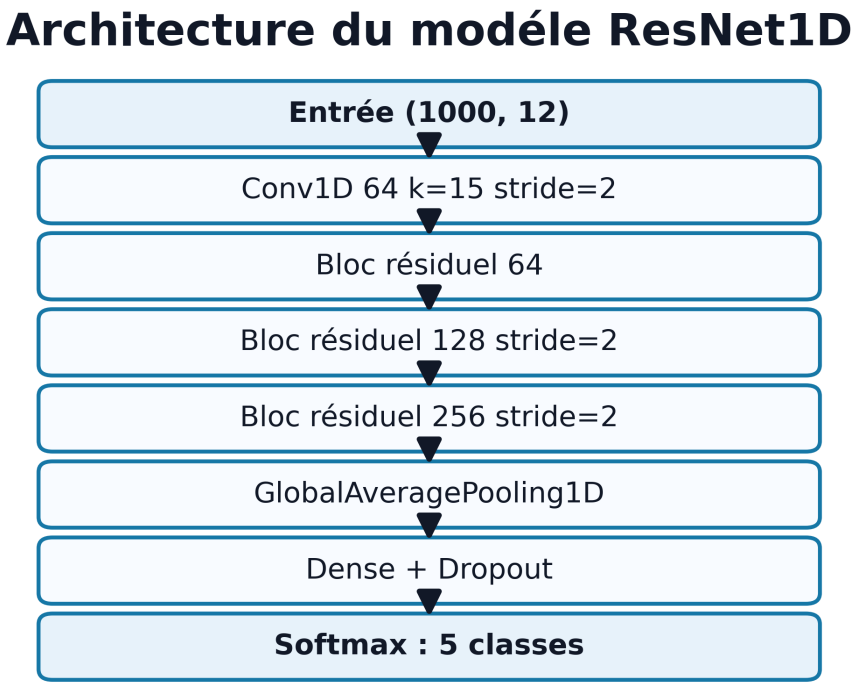


FIGURE 3.7 – Architecture du modèle ResNet1D

3.5.5 CNN optimisé

Un CNN optimisé a également été développé. Il ajoute une régularisation L2 et plusieurs couches de Dropout afin de réduire le surapprentissage. Ce modèle vise à améliorer le F1-score macro, particulièrement important lorsque les classes sont déséquilibrées.

La régularisation L2 pénalise les poids trop élevés, ce qui encourage le modèle à apprendre des représentations plus générales. Le Dropout désactive aléatoirement une partie des neurones pendant l'entraînement, ce qui réduit la dépendance excessive à certains chemins du réseau. Ces deux mécanismes améliorent généralement la généralisation.

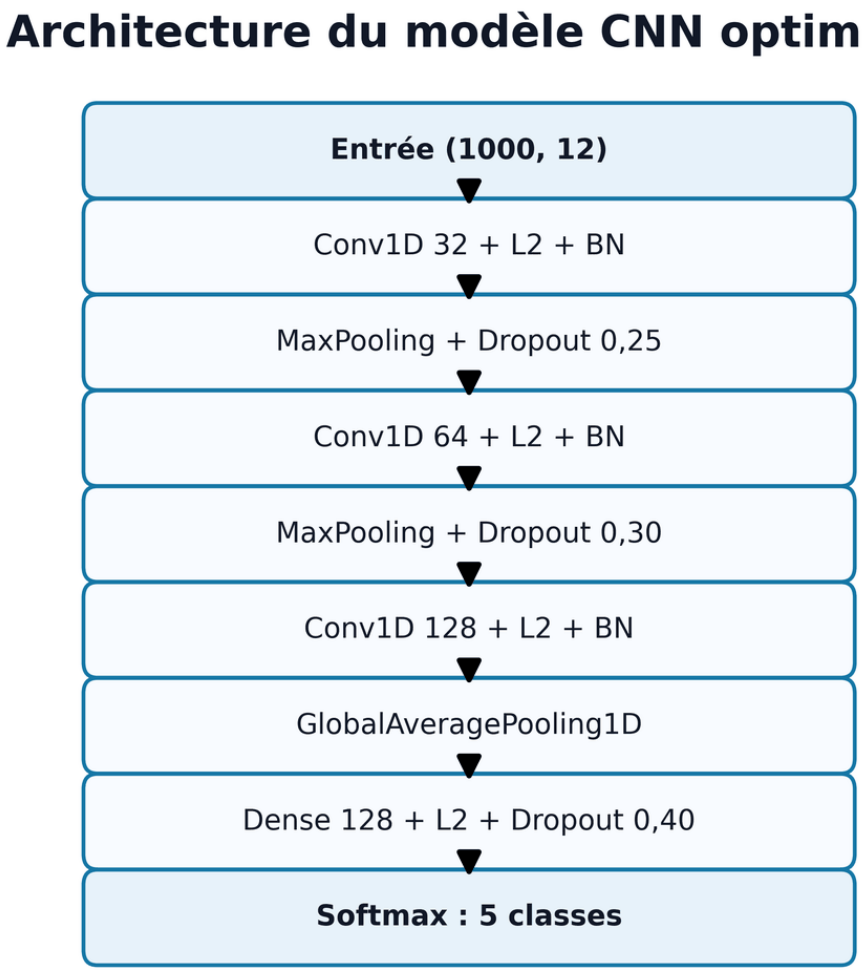


FIGURE 3.8 – Architecture du modèle CNN optimisé

3.6 Stratégie d'entraînement

L'entraînement des modèles repose sur plusieurs mécanismes destinés à améliorer la stabilité et la performance :

— **Early stopping :** arrêt automatique lorsque la performance de validation ne s'améliore plus.

— **ReduceLROnPlateau :** diminution du taux d'apprentissage lorsque la validation stagne.

— **ModelCheckpoint :** sauvegarde du meilleur modèle selon la performance de validation.

— **Class weights :** pondération des classes afin de compenser le déséquilibre du dataset.

Ces techniques sont importantes pour éviter que le modèle apprenne uniquement les particularités de l'ensemble d'entraînement. Elles permettent également de mieux gérer les classes minoritaires.

3.7 Environnement technique

Le projet est développé en Python. Les bibliothèques principales utilisées sont TensorFlow/Keras pour les modèles de Deep Learning, NumPy et Pandas pour la manipulation des données, WFDB pour le chargement des signaux ECG, Scikit-learn pour les métriques et Streamlit pour l'interface utilisateur.

Conclusion

Ce chapitre a détaillé la conception technique du système. Nous avons présenté le pipeline complet, l'extraction des labels, le prétraitement des signaux et les architectures développées. Les modèles construits sont ensuite entraînés et évalués dans le chapitre suivant afin de comparer leurs performances et de choisir celui qui sera intégré dans l'interface.

Chapitre 4

Résultats expérimentaux et interface utilisateur

Introduction

Ce chapitre présente les résultats obtenus dans le notebook d'expérimentation. Il rassemble les captures d'entraînement, les courbes d'apprentissage, les graphes de comparaison, les rapports de classification, les matrices de confusion et l'interface Streamlit. Chaque graphe est accompagné d'une explication afin de faciliter l'interprétation des performances.

4.1 Paramètres d'entraînement

Les modèles ont été entraînés avec les paramètres suivants :

Paramètre	**Valeur**
Optimiseur	Adam
Fonction de perte	Categorical Crossentropy
Batch size	32
Nombre maximal d'époques	30 à 40
Early stopping	Oui
Réduction du learning rate	Oui
Pondération des classes	Oui

TABLE 4.1 – Paramètres d'entraînement

La pondération des classes a été utilisée afin de réduire l'effet du déséquilibre entre les catégories diagnostiques. Cette stratégie donne plus d'importance aux classes minoritaires

pendant l'entraînement.

L'optimiseur Adam a été choisi car il adapte automatiquement le taux d'apprentissage pour chaque paramètre du réseau. Il est largement utilisé dans les projets de Deep Learning en raison de sa stabilité et de sa rapidité de convergence. La fonction de perte `categorical_crossentropy` est adaptée au problème de classification multi-classes avec sortie `softmax`.

Le batch size de 32 représente un compromis entre stabilité de l'apprentissage et consommation mémoire. Un batch trop petit peut rendre l'entraînement instable, tandis qu'un batch trop grand peut nécessiter plus de mémoire et réduire la capacité de généralisation.

4.2 Comparaison des modèles

Les performances obtenues sont résumées dans le graphe suivant. Cette comparaison synthétise les deux métriques principales : l'accuracy et le F1 macro.

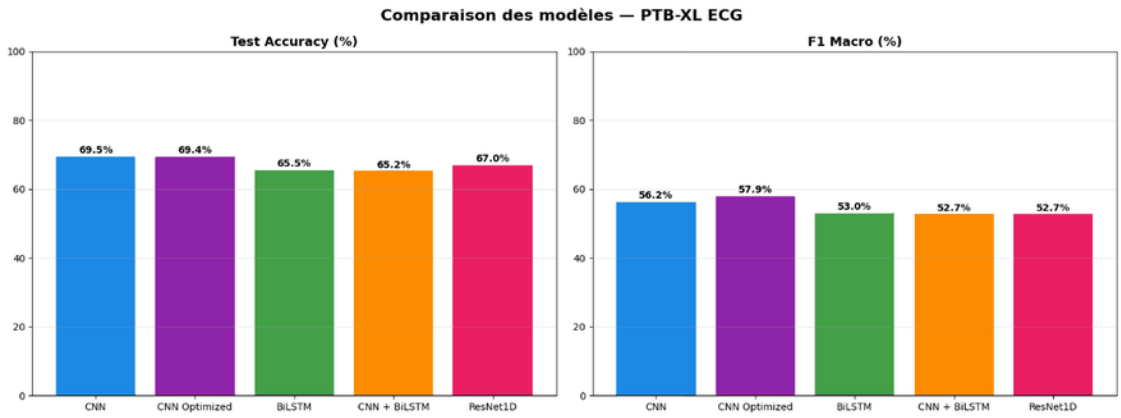


FIGURE 4.1 – Comparaison graphique des modèles selon l'accuracy et le F1 macro

La comparaison montre que les modèles plus complexes ne sont pas automatiquement meilleurs. Le CNN simple reste très compétitif, probablement parce que les motifs discriminants des ECG sont fortement liés à des formes locales. Le CNN optimisé obtient un F1 macro supérieur, ce qui indique une meilleure prise en compte des classes minoritaires.

Les modèles récurrents, bien qu'intéressants théoriquement, ne donnent pas les meilleurs

résultats dans cette configuration. Cela peut être dû à la taille du dataset, à la complexité des séquences, au déséquilibre des classes ou à la difficulté d'optimiser ces architectures.

4.3 Analyse des résultats

Le CNN simple obtient la meilleure accuracy globale avec 69.48%. Toutefois, le CNN optimisé obtient le meilleur F1 macro avec 57.85%. Le F1 macro est particulièrement important dans ce projet, car il donne le même poids à toutes les classes, y compris les classes minoritaires comme HYP.

Le modèle BiLSTM et le modèle CNN-BiLSTM présentent des performances plus faibles. Cela peut s'expliquer par la complexité temporelle des modèles récurrents et par le risque de surapprentissage. Le ResNet1D montre une performance correcte, mais reste inférieur au CNN sur cette configuration.

Il est important de distinguer l'accuracy et le F1 macro. L'accuracy mesure la proportion globale de prédictions correctes. Elle est utile pour avoir une vision générale de la performance, mais elle peut être influencée par la classe majoritaire. Le F1 macro, en revanche, accorde le même poids à chaque classe. Dans un contexte médical, cette métrique est plus informative lorsque certaines pathologies sont peu représentées.

Ainsi, même si le CNN simple possède une accuracy très légèrement supérieure, le CNN optimisé peut être considéré comme plus équilibré, car son F1 macro est meilleur. Ce résultat montre l'intérêt de comparer plusieurs métriques avant de sélectionner un modèle.

4.4 Rapports de classification

Le CNN simple donne de bons résultats sur la classe NORM, mais ses performances sont plus faibles sur HYP et MI. Cette observation confirme que les classes minoritaires sont plus difficiles à apprendre.

Classe	Précision	Recall	F1-score	Support
CD	0.69	0.70	0.70	863
HYP	0.19	0.19	0.19	219
MI	0.60	0.34	0.44	535
NORM	0.82	0.84	0.83	1839
STTC	0.60	0.73	0.66	863
Accuracy			0.69	
Macro avg	0.58	0.56	0.56	4319
Weighted avg	0.69	0.69	0.69	4319

TABLE 4.2 – Rapport de classification du modèle CNN

Le CNN optimisé améliore le F1 macro. Il présente notamment une amélioration du rappel de la classe HYP et du F1-score de la classe MI, ce qui le rend intéressant dans un contexte où l'équilibre entre classes est important.

Classe	Précision	Recall	F1-score	Support
CD	0.65	0.73	0.69	863
HYP	0.22	0.26	0.24	219
MI	0.57	0.44	0.50	535
NORM	0.81	0.85	0.83	1839
STTC	0.69	0.60	0.64	863
Accuracy			0.69	
Macro avg	0.59	0.58	0.58	4319
Weighted avg	0.69	0.69	0.69	4319

TABLE 4.3 – Rapport de classification du modèle CNN optimisé

4.4.1 Interprétation par classe

La classe NORM est la mieux reconnue. Cela s'explique par son nombre important d'exemples et par le fait qu'un ECG normal possède généralement une structure plus régulière. La classe CD obtient également des résultats corrects, car les troubles de conduction peuvent produire des modifications relativement visibles dans le complexe QRS.

La classe MI reste plus difficile à détecter. L'infarctus du myocarde peut produire des variations différentes selon la localisation et l'intensité de l'atteinte. Certaines manifestations peuvent se rapprocher d'autres classes, ce qui entraîne des confusions.

La classe HYP est la plus problématique. Elle possède peu d'exemples dans le dataset et ses caractéristiques peuvent être moins évidentes à apprendre pour un modèle entraîné sur des signaux bruts. Ce résultat montre la nécessité d'améliorer la gestion des classes minoritaires.

4.4.2 Analyse des erreurs

Les erreurs du modèle ne doivent pas être interprétées uniquement comme des échecs techniques. Dans un contexte ECG, certaines classes peuvent partager des motifs similaires. Par exemple, des anomalies ST/T peuvent être associées à d'autres pathologies, et certains signaux peuvent contenir plusieurs indications diagnostiques. Le fait de retenir une seule classe principale simplifie le problème, mais peut aussi masquer la complexité clinique de certains ECG.

Une amélioration possible serait de transformer le problème en classification multi-label, où un ECG pourrait appartenir à plusieurs classes simultanément. Cette approche serait plus proche de la réalité médicale, mais elle nécessiterait une adaptation du pipeline, des labels et des métriques.

4.5 Courbes d'apprentissage et matrices de confusion

Dans cette partie, nous nous concentrons uniquement sur les deux modèles les plus importants pour notre projet : le CNN simple et le CNN optimisé. Le CNN simple est le modèle retenu pour l'interface, car il obtient la meilleure performance globale en accuracy. Le CNN optimisé est conservé dans l'analyse, car il obtient le meilleur F1 macro et permet donc d'observer l'effet de la régularisation sur l'équilibre entre les classes.

4.5.1 Courbe d'apprentissage du modèle CNN

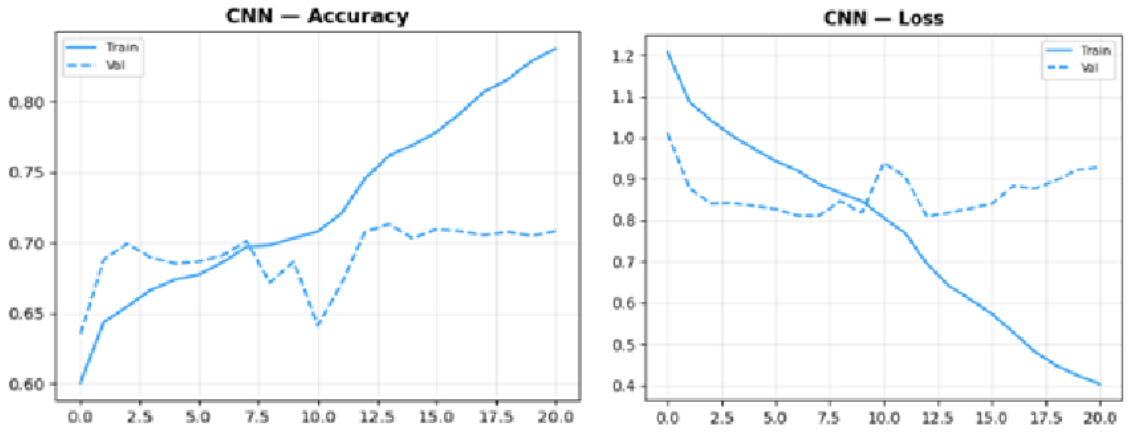


FIGURE 4.2 – Courbes d'apprentissage du modèle CNN

Les courbes du CNN montrent une progression nette de l'accuracy d'entraînement. La validation se stabilise plus tôt, ce qui indique que le modèle commence à apprendre des détails spécifiques aux données d'entraînement. Malgré cela, le CNN reste le meilleur modèle en performance globale avec une accuracy de test de 69.48%.

4.5.2 Matrice de confusion du modèle CNN

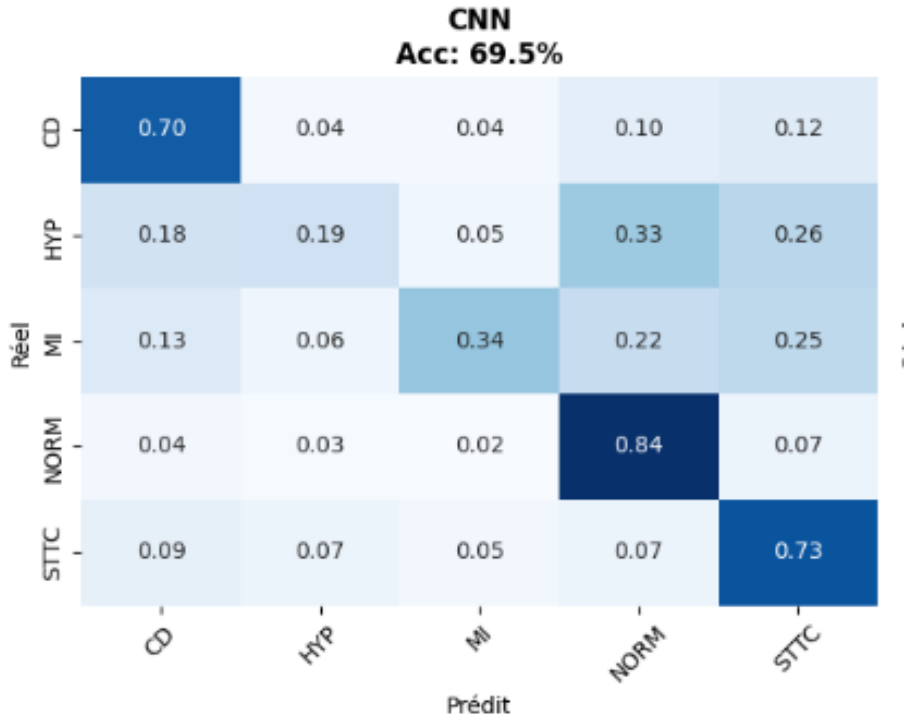


FIGURE 4.3 – Matrice de confusion normalisée du modèle CNN

La matrice de confusion du CNN montre que la classe NORM est bien reconnue. Les classes minoritaires, notamment HYP et MI, restent plus difficiles à classifier. Cette observation est cohérente avec le déséquilibre du dataset PTB-XL.

4.5.3 Courbe d'apprentissage du modèle CNN optimisé

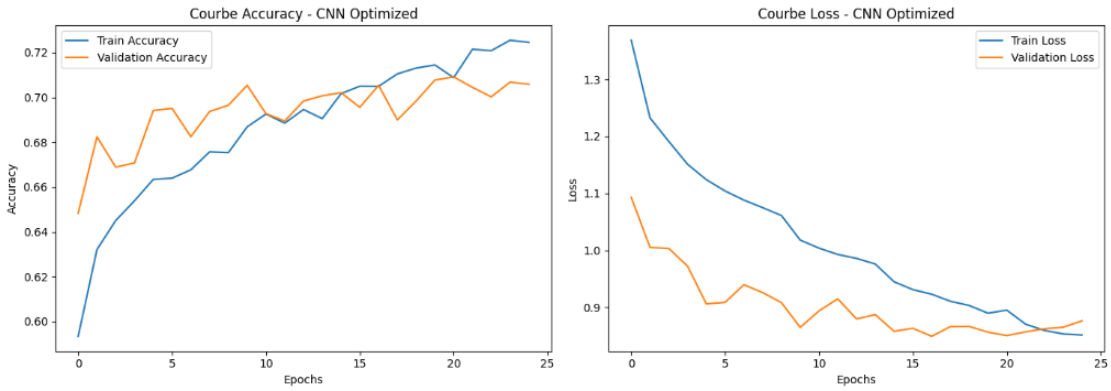


FIGURE 4.4 – Courbes d'apprentissage du modèle CNN optimisé

Le CNN optimisé bénéficie de la régularisation L2 et du Dropout. Ces mécanismes permettent de limiter le surapprentissage et d'améliorer le F1 macro. Même si son accuracy globale est légèrement inférieure à celle du CNN simple, il offre une meilleure performance moyenne entre les classes.

4.5.4 Matrice de confusion du modèle CNN optimisé

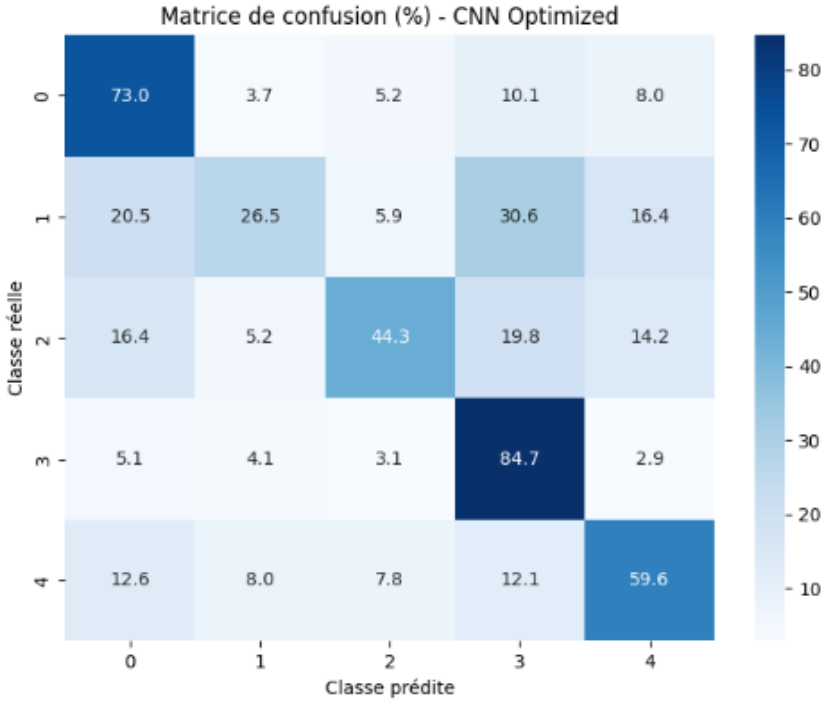


FIGURE 4.5 – Matrice de confusion normalisée du modèle CNN optimisé

La matrice de confusion du CNN optimisé montre une amélioration relative sur certaines classes minoritaires. Ce modèle est donc intéressant lorsque l'objectif principal est l'équilibre entre les classes. Cependant, pour l'interface finale, nous avons choisi le CNN simple, car il possède la meilleure performance globale en accuracy.

4.6 Interface utilisateur Streamlit

Une interface Streamlit a été développée afin de rendre le modèle utilisable de manière simple. Elle permet à l'utilisateur d'importer un fichier ECG au format `.npy`, de visualiser une dérivation et d'obtenir la prédiction du modèle.

L'objectif de l'interface est de démontrer l'intégration du modèle dans une application exploitable par un utilisateur non spécialiste en programmation. Elle transforme le modèle entraîné en un outil interactif où l'utilisateur peut charger un signal, le visualiser et obtenir un résultat de classification.

4.7 Modèle choisi pour l'interface

L'application intègre le modèle CNN simple, sauvegardé sous le fichier cnn$_m$*odel.keras*, *quiobtientlam*

L'interface propose les fonctionnalités suivantes :

— importation d'un signal ECG au format `.npy` ;

— vérification automatique de la dimension du signal ;

— sélection d'une dérivation parmi les 12 dérivations ECG ;

— affichage graphique du signal ;

— prédiction automatique de la classe diagnostique ;

— affichage du niveau de confiance ;

— affichage des probabilités pour toutes les classes.

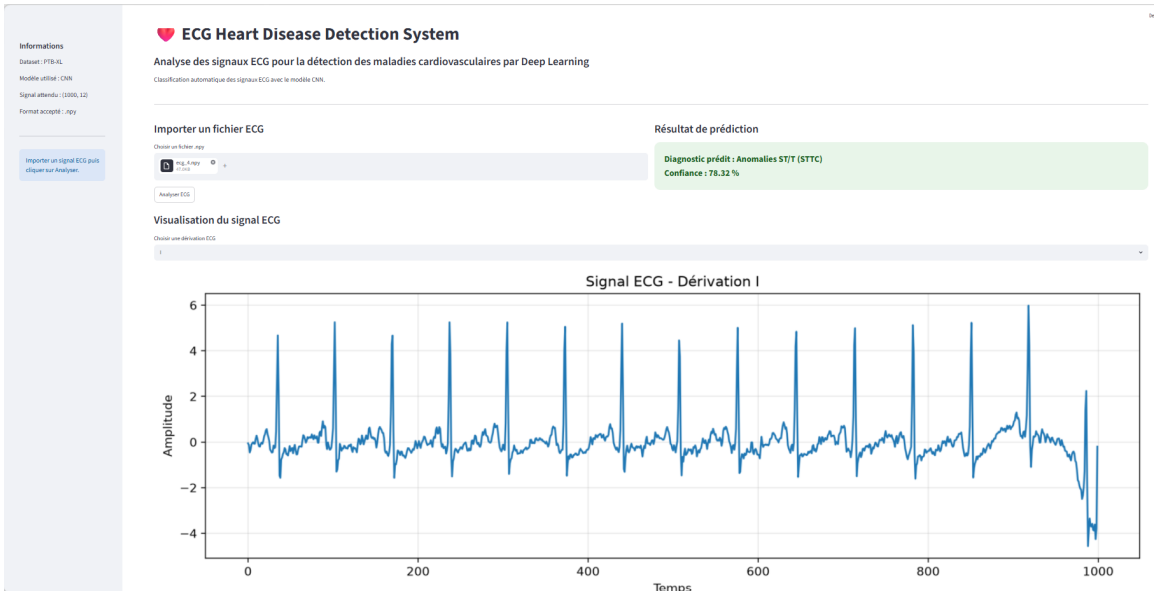


FIGURE 4.6 – Figure del'interface (1)

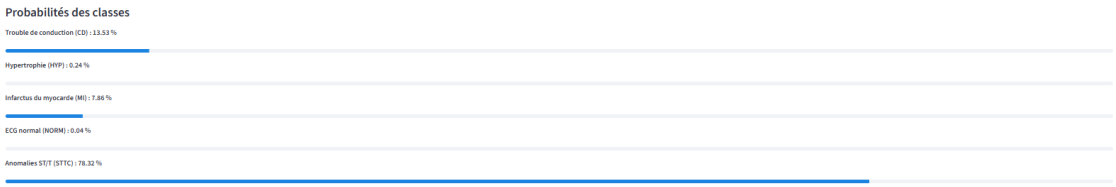


FIGURE 4.7 – Figure del'interface (2)

4.8 Discussion

Les résultats montrent que les modèles sont capables d'apprendre des motifs ECG pertinents. Cependant, la performance reste limitée par plusieurs facteurs : le déséquilibre important entre les classes, la difficulté de distinguer certaines pathologies proches, la faible représentation de la classe HYP, la complexité des signaux ECG réels et l'absence d'explicabilité médicale dans la version actuelle.

Malgré ces limites, le système constitue une base fonctionnelle pour l'aide à la détection automatique des anomalies cardiovasculaires.

Conclusion

Ce chapitre a présenté les résultats expérimentaux obtenus dans le notebook ainsi que l'interface Streamlit développée. Les graphes montrent que le CNN simple obtient la meilleure accuracy, tandis que le CNN optimisé offre le meilleur F1 macro. L'interface actuelle utilise le modèle CNN sauvegardé dans le fichier `cnn_model.keras`. Le chapitre suivant présente les limites du travail et les perspectives d'amélioration.

Chapitre 5

Limites et perspectives

Introduction

Ce dernier chapitre présente les limites du projet et les pistes d'amélioration possibles. Il met en évidence les aspects qui doivent être renforcés pour rendre le système plus robuste, plus explicable et plus proche d'une utilisation réelle.

5.1 Limites du projet

Le système développé présente plusieurs limites. Premièrement, les performances restent modestes sur certaines classes minoritaires, en particulier HYP. Deuxièmement, les résultats dépendent fortement du dataset PTB-XL et ne garantissent pas une généralisation immédiate à d'autres bases de données ou à des ECG réels provenant d'autres appareils. Troisièmement, le modèle fonctionne comme une boîte noire et ne fournit pas encore une explication détaillée des zones du signal utilisées pour la décision.

L'interface constitue également une preuve de concept. Elle accepte uniquement des fichiers `.npy` de dimension exacte `(1000, 12)`. Elle ne remplace pas un diagnostic médical professionnel et doit être présentée comme un outil d'aide à la décision.

Une autre limite concerne la formulation du problème. Le projet considère une classification mono-label, c'est-à-dire qu'un ECG est associé à une seule classe principale. Or, dans la réalité médicale, un même ECG peut présenter plusieurs anomalies. Une classification multi-label serait donc plus réaliste, mais aussi plus complexe à mettre en oeuvre.

Enfin, les résultats ne sont pas validés dans un contexte clinique réel. Les performances obtenues sur PTB-XL donnent une indication expérimentale, mais elles ne suffisent pas

pour conclure à une utilisation médicale directe. Une telle utilisation nécessiterait une validation plus large, avec des données provenant de plusieurs sources et une évaluation par des spécialistes.

5.2 Perspectives d'amélioration

Plusieurs améliorations peuvent être envisagées :

— appliquer de la data augmentation sur les signaux ECG ;

— utiliser une fonction de perte de type focal loss ;

— tester des modèles à attention ou des Transformers 1D ;

— ajouter des méthodes d'explicabilité comme Grad-CAM 1D ou saliency maps ;

— accepter d'autres formats de fichiers comme CSV ;

— afficher les 12 dérivations simultanément ;

— améliorer la gestion des classes minoritaires ;

— valider le modèle sur un autre dataset ECG ;

— intégrer un message d'alerte lorsque la confiance du modèle est faible.

5.2.1 Amélioration des performances

Pour améliorer les performances, plusieurs pistes peuvent être étudiées. La première consiste à appliquer de la data augmentation spécifique aux ECG, par exemple l'ajout de bruit contrôlé, le décalage temporel, la variation légère d'amplitude ou la simulation de perturbations réalistes. Cette stratégie peut aider le modèle à mieux généraliser.

La deuxième piste concerne les classes minoritaires. Il serait possible d'utiliser un sur-échantillonnage contrôlé, une focal loss ou des stratégies de rééquilibrage plus avancées. L'objectif serait d'améliorer le recall des classes pathologiques peu représentées.

5.2.2 Amélioration de l'explicabilité

L'explicabilité est très importante dans un projet médical. Un modèle qui fournit uniquement une classe prédite reste difficile à interpréter. Des méthodes comme Grad-CAM 1D, les saliency maps ou l'occlusion sensitivity pourraient être ajoutées afin d'identifier les zones du signal qui influencent le plus la prédiction.

Ces méthodes permettraient d'afficher dans l'interface les parties du signal jugées importantes par le modèle. Cela rendrait le système plus transparent et plus utile pour l'analyse.

5.2.3 Amélioration de l'interface

L'interface peut être enrichie en acceptant des fichiers `.csv`, en affichant les douze dérivations simultanément et en proposant un rapport automatique de prédiction. Elle peut également inclure un message de prudence lorsque la confiance est faible ou lorsque deux classes ont des probabilités proches.

Conclusion

Ce chapitre a mis en évidence les limites du système et les améliorations possibles. Les perspectives les plus importantes concernent l'amélioration des classes minoritaires, l'ajout de l'explicabilité, l'enrichissement de l'interface et la validation du modèle sur d'autres données ECG.

Conclusion générale

Ce projet de fin d'année a porté sur l'analyse automatique des signaux ECG pour la détection et la prédiction des maladies cardiovasculaires à l'aide des techniques de Deep Learning. L'objectif était de construire un pipeline complet, depuis le chargement des données jusqu'à l'intégration du modèle dans une interface utilisateur.

Le dataset PTB-XL a été utilisé comme base expérimentale. Les signaux ECG à 12 dérivations ont été prétraités à l'aide d'un filtrage passe-bande, d'une normalisation et d'une mise en forme fixe de dimension `(1000, 12)`. Les labels diagnostiques ont été extraits à partir des codes SCP afin de construire un problème de classification à cinq classes : NORM, MI, STTC, CD et HYP.

Plusieurs architectures ont été développées et comparées : CNN, BiLSTM, CNN-BiLSTM, ResNet1D et CNN optimisé. Les résultats montrent que le CNN simple obtient la meilleure accuracy globale, avec 69.48%, tandis que le CNN optimisé obtient le meilleur F1 macro, avec 57.85%. Cette différence montre l'importance d'utiliser plusieurs métriques dans un contexte médical, surtout lorsque les classes sont déséquilibrées.

Une interface Streamlit a été réalisée afin de permettre l'importation d'un signal ECG, la visualisation d'une dérivation et l'affichage du diagnostic prédit avec les probabilités des classes. Le modèle actuellement utilisé dans l'interface est le CNN sauvegardé sous le nom `cnn_model.keras`.

En conclusion, le projet atteint son objectif principal : proposer une solution fonctionnelle de classification automatique des signaux ECG. Il constitue une base solide pour un système d'aide à la décision médicale. Néanmoins, des améliorations restent nécessaires, notamment l'explicabilité du modèle, la gestion des classes minoritaires, l'acceptation de nouveaux formats de fichiers et la validation sur d'autres bases de données.

Bibliographie

1. PTB-XL Dataset – Scientific Data : https://www.nature.com/articles/s41597-020-0495-6
2. PTB-XL Dataset – PhysioNet : https://physionet.org/content/ptb-xl/1.0.3/
3. Deep Learning for ECG Analysis – PTB-XL Benchmark : https://arxiv.org/abs/2004.13701
4. Cardiologist-Level Arrhythmia Detection – Nature Medicine : https://www.nature.com/articles/s41591-018-0268-3
5. Deep Residual Learning for Image Recognition – ResNet : https://arxiv.org/abs/1512.03385
6. Long Short-Term Memory – LSTM : https://direct.mit.edu/neco/article/9/8/1735/6109/Long-Short-Term-Memory
7. Deep Learning Book : https://www.deeplearningbook.org/

Annexes

5.3 Exemple de pipeline d'entraînement

Listing 5.1 – Principe général d'entraînement

```
model.compile(
    optimizer=Adam(1e-3),
    loss="categorical_crossentropy",
    metrics=["accuracy"]
)

callbacks = [
    EarlyStopping(monitor="val_loss", patience=8, restore_best_weights=True
    ReduceLROnPlateau(monitor="val_loss", factor=0.5, patience=4),
    ModelCheckpoint("best_model.keras", monitor="val_accuracy", save_best_
]

history = model.fit(
    X_train,
    y_train_oh,
    validation_data=(X_val, y_val_oh),
    epochs=30,
    batch_size=32,
    class_weight=class_weight_dict,
    callbacks=callbacks
)
```

5.4 Classes utilisées dans l'interface

Listing 5.2 – Mapping des classes diagnostiques

```
class_names_full = {
    "NORM": "ECG normal",
    "MI": "Infarctus du myocarde",
    "STTC": "Anomalies ST/T",
    "CD": "Trouble de conduction",
    "HYP": "Hypertrophie"
}
```

5.5 Prétraitement du signal

Listing 5.3 – Filtrage et normalisation d'un signal ECG

```
def bandpass_filter(signal, lowcut=0.5, highcut=40.0, fs=100, order=4):
    nyq = 0.5 * fs
    b, a = butter(order, [lowcut / nyq, highcut / nyq], btype="band")
    return filtfilt(b, a, signal, axis=0)


def normalize_signal(signal):
    return (signal - signal.mean(axis=0)) / (signal.std(axis=0) + 1e-8)
```